

SAĞLIKTA YAPAY ZEKA YARIŞMASI PROJE SUNUŞ RAPORU

GÖREV: Missense Genetik Varyantların Patojenik /Benign Olarak Sınıflandırılması

Yarışma Eğitim Seviyesi: Üniversite ve Üzeri

Proje Adı: Missense Varyantların Sınıflandırılması

Takım Adı: MedicalVision

Takım ID: 752966


Başvuru ID: 4722798



İÇİNDEKİLER

1. TAKIM ŞEMASI.....	2
2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ ...	2
3. KULLANILAN VERİ SETİ VE ALGORİTMALAR	3
3.1 Kullanılan Veri Seti ve Etiketler.....	3
3.2 Veri Kısıtları ve Etikete Doğrudan Erişimi Engelleme.....	4
3.3 Veri Ön İşleme ve Temsilleme Stratejisi.....	4
3.4 Etiket Güvenilirliği ve Veri Kalitesi Kontrolü.....	5
3.5 Sınıf Dengesi ve Risk Perspektifi.....	5
3.6 Seçilen Algoritmalar ve Gerekçe.....	5
4.DENEY TASARIMI, SONUÇLAR VE İNCELEME.....	5
4.1 Deney Protokolü ve Veri Bölme.....	6
4.2 Performans Metrikleri ve Panel Bazlı Raporlama.....	6
4.3 Hata Analizi ve Model Davranışı.....	6
4.4 “Model Neden Böyle Karar Verdi?” – Açıklanabilirlik Yaklaşımı.....	7
4.5 Öğrenme Süreci ve Teknik Evrim	7
5.YAKLAŞIMIN GEREKÇESİ, KAYNAK KULLANIMI VE ÖZGÜNLÜK.....	8
5.1 Neden Bu Algoritma / Mimari?	8
5.2 Alternatifler Neden Elendi?	8
5.3 Parametre Seçimi ve Model Ayarları	9
5.4 Hesaplama Kaynakları ve Çalıştırılabilirlik	9
5.5 Özgünlük	10
6.REFERANSLAR	11

1. TAKIM ŞEMASI



2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ (10 PUAN)

Lai vd. (2021) tarafından yapılan çalışmada; Yanlış anlamlı varyantların patojenite tahmininde araçların farklı veri modelleriyle çalışabilmesi sağlanmıştır. Protein dinamiği, dizi ve yapı özelliklerine 'varyasyon numarası' eklenerek XGBoost tabanlı LYRUS modeli geliştirilmiştir. Modelin eğitimi için ClinVar'dan 22.639 varyant kullanılırken test aşamasında VariBench ve bağımsız DMS veri setleri tercih edilmiştir. Modelin 0.932 AUROC skoru ile mevcut popüler araçlarla eşdeğer veya üstün bir performans gösterdiği kanıtlanmıştır. Modelin, 3 boyutlu protein yapılarına (PDB) tam bağımlılığı, yöntem açısından temel bir kısıt olarak ortaya konmuştur [1]

Mahecha vd. (2022) tarafından yapılan çalışmada; klinik tanıyı zorlaştıran önemi belirsiz varyantların (VUS) patojenitesini sınıflandırma problemi ele alınmıştır. Random Forest (RF), SVM ve MLP algoritmaları kıyaslanarak en iyi performansı veren RF tabanlı açık kaynaklı "VusPrize" aracı geliştirilmiştir. Eğitim için ClinVar'dan 76.049 kaliteli varyant, test için ise VUS'tan diğer sınıflara geçen 5.526 varyant kullanılmıştır. RF modeli genel testlerde 0.98 AUC skoru ile diğer araçları geride bırakmıştır. Synonymous varyantların benign olarak tahmin edilmesi eğilimi, modelin raporlanan sınırlılıklarından biri olmuştur [2].

Wu vd. (2021) tarafından yapılan çalışmada; Eğitim veri setlerinin büyütülmesi sürecinde veri kalitesinin düşme riski ve döngüsellik sorunları ele alınmıştır. Çekirdek ve eklenti verilerin kalite farklılıklarını lojistik fonksiyonlarla hesaba katan XGBoost tabanlı VARIETY modeli ortaya konmuştur. ClinVar'dan nadir varyantlar çekirdek seti oluştururken, gnomAD, HGMD ve MAVE verileri eklenti olarak kullanılmıştır. VARIETY modeli, nadir varyantlar testinde popüler araçları açık ara geride bırakmıştır. Yöntemin biyolojik etki

mekanizmalarını doğrudan modellememesi ve CADD benzeri araçların rekabet açısından avantaj sağlaması, kısıtlılık olarak belirtilmiştir [3].


Liu vd. (2024) tarafından yapılan çalışmada; missense varyantların patojenite sınıflandırmasında genel modellerin sınırlara ulaşması sorunu ele alınmıştır. AlphaFold2 yapısal öngörülerini kodlayıcı-kod çözücü ağ yapısı ve ShuffleNet tabanlı derin öğrenme mimarisi ile entegre eden MissenseNet modeli geliştirilmiştir. GnomAD ve ClinVar veri tabanlarından elde edilen yüz binlerce varyant kullanılmıştır. Model, %91,82 doğruluk ve 0.9701 AUC skoru ile diğer makine öğrenmesi yöntemlerini geride bırakmıştır. AlphaFold2 yapısal özelliklerinin düzensiz (disordered) bölgelerde yapısal karmaşıklığın tam olarak ifade edilememesi riski, çalışma kısıtı olarak rapor edilmiştir [4].

Schmidt vd. (2023) tarafından yapılan çalışmada; deneysel 3 boyutlu protein yapı bilgisinin yetersizliği nedeniyle patojenite skorlarının yapısal veriyi kullanamaması sorunu ele alınmıştır. (AlphaFold2 tarafından öngörülen çözücü erişilebilirliği ve pLDDT skoru gibi özellikleri rastgele orman (RF) algoritması ile birleştiren AlphScore modeli sunulmuştur. GnomAD popülasyon verileri ve ClinVar varyantları ile derin mutasyonel tarama (DMS) verileri kullanılmış, AlphScore CADD ve REVEL gibi skorlara eklendiğinde bu araçların tanısallık doğruluğunu belirgin şekilde arttırmıştır. AlphaFold2 özelliklerinin eksikliğinde modelin performansında yaşanan düşüşler, sınırlılık olarak rapor edilmiştir.[5]

3. VERİ VE YÖNTEM (30 PUAN)

3.1 Kullanılan Veri Seti ve Etiketler (5 puan)

'Doğru Sınıf' kavramına uygun, iki genetik veritabanından veriler birleştirilmiştir. Klinik olarak doğrulanmış ClinVar veritabanındaki veriler sağlanmış ardından verideki sınıf dengesizliğinin tespit edilmesi nedeniyle gnomAD veritabanından ekleme yapılmıştır. İki kaynağın entegrasyonundan elde edilen ham veri setindeki 'Klinik açıdan belirsiz (VUS)' veya çelişkili (conflicting) etiketler veri setinden çıkarılmıştır. Kalan veri kümesi ACMG standartlarına uygun biçimde ikili sınıflandırma problemine dönüştürülmüş; 'Pathogenic/Likely Pathogenic' sınıfları 1, 'Benign/Likely Benign' sınıfları ise 0 olarak belirlenmiştir.



Tablo1:Panel Bazlı Veri Dağılım Grafiği

PAH ve CFTR panellerinde Benign sınıfı hastalık odaklı gen yapısı nedeniyle doğal olarak kısıtlı kalmaktadır. Tüm panellerde sabit train/test ayrımı yerine Repeated Stratified 5-Fold CV (5 fold $\times$ 3 tekrar = 15 değerlendirme) tercih edilmiş, böylece her örnek üç farklı bölünmede test edilerek küçük örneklemden kaynaklanan varyans riski minimize edilmiştir.

3.2 Veri Kısıtları ve Etikete Doğrudan Erişimi Engelleme (5 puan)

Modelin varyant etiketlerini dış kaynaklardan ezberlemesini önlemek için kapsamlı bir ayrıştırma yapılmıştır. Bu kapsamda varyantı doğrudan teşhis edebilecek genomik adres bilgileri (Kromozom, Lokasyon/Pozisyon) gibi veriler modelin öğrenme sürecine dahil edilmemiştir. Varyant profilleri, evrimsel hizalamalar ve biyokimyasal değişimlerin matematiksel ifadeleri üzerinden tahmin yapacak şekilde modellenmiştir. Dolaylı sızıntı riskini kontrol etmek için De-duplikasyon aşamasında aynı amino asit değişimini ifade eden tekrarlı kayıtlar VARITY standardına göre temizlenmiş; aynı varyantın türevi örneklerin farklı fold'lara düşmesi engellenmiştir. REVEL ve PolyPhen-2 skorları kendi eğitimlerinde ClinVar etiketlerini kullandıklarından hedef değişkenle döngüsel ilişki riski taşıdığı için çıkarılmış; bunların yerine yalnızca evrimsel hizalamaya dayanan SIFT ve PhyloP ile sentetik mutasyonlarla eğitilmiş CADD skoru kullanılmıştır. Repeated Stratified 5-Fold CV uygulanmış; her fold'da sınıf dağılımı korunarak rastlantısal iyi sonuç riski minimize edilmiştir. Normalizasyon parametreleri yalnızca eğitim seti üzerinden hesaplanmış, test setine yansıtılmıştır.

3.3 Veri Ön İşleme ve Temsilleme Stratejisi (5 puan)

Modellerin veriyi en iyi verimi alacak biçimde işleyebilmesi için çok katmanlı bir ön işleme analiz hattı (pipeline) kurulmuştur. Patojenisite skorlarındaki eksik değerler medyanla, popülasyon frekans sütunlarındaki eksiklikler sıfırla doldurulmuştur. Bunun sebebi bir varyantın veritabanında bulunmaması o varyantın sağlıklı popülasyonda gözlemlenmediğini ifade etmektedir. Proteomik komşuluk bilgisinin hesaplanmadığı satırlar NaN olarak bırakılmış, bunun yerine bir bayrak sütunu (Missing Indicator) eklenerek modelin eksikliği öğrenmesi sağlanmıştır.

Popülasyon verilerinden her bir sayım sütunu için iki türetilmiş özellik oluşturulmuştur: Tüm popülasyonlardaki değerlerin toplamı (Total_Homozygotes) ve en az bir bireyin varlığı (Is_Homozygote_Present) gösterilmiştir. Bunun nedeni yapılan bazı çalışmalarda gerçek zararsız varyantların %47.75'inde en az bir homozigot birey gözlemlenirken, patojenik varyantlarda bu oran yalnızca %1.51'dir. Allele Frequency gibi 10^{-6} seviyesinde sağa çarpık dağılım gösteren sütunlara önce $\log(1+x)$ dönüşümü uygulanmış, ardından Min-Max ile 0-1 aralığına sıkıştırılmıştır; log dönüşümünün amacı algoritmaların çok küçük değerler arasındaki farkları öğrenememesi sorununu gidermektir. Amino asit değişiminden türetilen biyokimyasal fark skorları pozitif ve negatif değer alabildiğinden StandardScaler ile ortalama 0 standart sapma 1 olacak

şekilde normalize edilmiştir. Delta skorlarına Min-Max yerine StandardScaler uygulanmasının nedeni bu skorların 0-1 aralığıyla sınırlı olmaması; pozitif ve negatif yön bilgisinin korunması gerekliliğidir. Sabit aralıklı patojenisite skorlarına ise Min-Max uygulanmıştır. Bu skorların zaten tanımlı aralıkları bulunduğundan ek dönüşüme gerek duyulmamıştır. Son olarak metin formatındaki genomik ve proteomik komşuluk dizileri 3'lü parçalara bölünüp Word2Vec ile 32'şer boyutlu vektörlere dönüştürülmüştür; bu yöntem benzer biyolojik bağlamlardaki dizilerin birbirine yakın vektörler almasını sağlamaktadır. Tüm normalizasyon parametreleri yalnızca eğitim verisi üzerinden hesaplanmış olup test verisine yansıtılarak veri sızıntısı önlenmiştir.

3.4 Etiket Güvenilirliği ve Veri Kalitesi Kontrolü (5 puan)

Farklı transkriptlerin birleşmesi sonucu aynı amino asit değişimine yol açan tekrarlı varyant kayıtları tespit edilmiştir. VARIETY standardına göre tekrarlı kayıt kontrolü yapılmış; tekilleştirme sırasında rastgele bir seçim yapmak yerine, klinik risk prensibi gereği en yüksek in silico risk skoruna sahip kopyalar veri setinde tutulmuştur. Transkript uyuşmazlığı tespit edile satırlarda hatalı bilginin modele sunulması engellenmiş, belirsiz sınıflandırma içeren kayıtlar çıkarılmıştır. Ayrıca eğitimde ClinVar gibi klinik etiketleri kullanan REVEL, PolyPhen gibi araçlar sistemden çıkarılmış; bunun yerine doğrudan CADD, PhyloP ve SIFT metrikleri kullanılmıştır. Yalnızca ACMG uyumlu dört etiket kategorisi (Pathogenic, Likely Pathogenic, Benign, Likely Benign) modele dahil edilmiş; VUS ve Conflicting Classifications gibi belirsiz kategoriler çıkarılmıştır.

3.5 Sınıf Dengesi ve Risk Perspektifi (5 puan)

Genel veri setinin sınıf dağılımı dengeli olmakla birlikte PAH ve CFTR panellerinde Benign sınıfı doğal olarak kısıtlıdır. Bu dengesizlikte tek bir metriğin yanıltıcı olabileceği göz önüne alınarak MCC ve Macro F1 birincil değerlendirme metrikleri olarak belirlenmiştir. Klinik açıdan yanlış negatifin yanlış pozitiften çok daha yüksek risk taşıması nedeniyle karar eşiği Macro F1'i maksimize ederken Recall'u 0.90 üzerinde tutan noktaya kalibre edilmiştir. PAH panelinde Macro F1: 0.8972, MCC: 0.7963, Recall: 0.9249; CFTR panelinde Macro F1: 0.8523, MCC: 0.7402, Recall: 0.9565 elde edilmiştir.

3.6 Seçilen Algoritmalar ve Gerekçe (5 puan)

Karar mekanizması için, tabular yapıdaki in-silico risk skorları, dil modeli gömmeleri (embeddings) ve popülasyon frekansları arasındaki karmaşık ilişkileri iyi öğrenen Gradient Boosting Decision Trees (XGBoost, LightGBM, CatBoost) mimarileri tercih edilmiştir. Bu algoritmalar; verimizdeki çok boyutlu yapıları hızlı işlemeleri, eksik verileri tolere edebilmeleri ve en önemlisi SHAP kütüphanesiyle olan uyumları sebebiyle seçilmiştir. Böylece sistemin 'Patojenik' kararına varırken evrimsel korunuma mı yoksa fizikokimyasal farklarına mı dayandığı (Feature Importance) jüriye en net biçimde sunulabilecektir.

4. DENEY TASARIMI, SONUÇLAR VE İNCELEME (25 PUAN)

4.1 Deney Protokolü ve Veri Bölme (5 puan)

Dengesiz sınıf dağılımı, modelin azınlık sınıfını görmezden gelerek overfitting'e sebep olmaktadır. Düzenlediğimiz genel veride dengeli bir yapı yakalamamıza rağmen, PAH ve CFTR panelinde yüksek dengesizlik tespit edilmiştir. "Rastlantısal iyi sonuç" riskini engellemek amacıyla hiperparametre seçiminde Optuna kütüphanesindeki TPESampler algoritması kullanılarak, 3-Katlı Katmanlı Çapraz Doğrulama (Stratified 3-Fold CV) döngüsü ile ortalama F1 skorunu maksimize edecek şekilde 30 deneme (trial) ile yapılmıştır. Optimize edilen algoritmaların birbiriyle karşılaştırılması ve ensemble (Stacking/Soft Voting) mimarilerinin performanslarının test edilmesi, veri sızıntısını engelleyen 5-Katlı Out-of-Fold (OOF) tahminleri üzerinden yapılmıştır.

4.2 Performans Metrikleri ve Panel Bazlı Raporlama (5 puan)

Asimetrik dağılımlarda algoritmaların her iki sınıftaki (Pozitif/Negatif) başarısını şeffaf bir şekilde ölçen MCC (Matthews Korelasyon Katsayısı) ve Macro F1-Skoru birincil optimizasyon metriği olarak kullanılmıştır.

Macro F1-Skoru, her iki sınıfın F1 değerini eşit ağırlıkla ortalayıp çoğunluk sınıfına odaklanarak yanlışlık gösteren modelleri cezalandırır. Bu sayede azınlık sınıflarındaki öğrenme kabiliyetini şeffaflaştırır. MCC, Karmaşıklık Matrisinin tamamını işleme katarak modelin yalnızca büyük olan sınıfı değil, her iki sınıfı da rastgele tahminden bağımsız olarak ne kadar güçlü ayırt edebildiğini güvenilir bir şekilde skorlamayı hedefler. Bu durum dengesiz test kümelerinde modelin ezber yapıp yapmadığını gösteren önemli bir performans metriğidir.

Karar eşiği, varsayılan 0.5 değerinde bırakılmamıştır. Pratikte patojenik bir varyantı gözden kaçırmanın hasta sağlığı üzerinde büyük riskler barındırması nedeniyle, karar mekanizması OOF (Out-of-Fold) tahminleri kullanılarak optimize edilmiştir. Karar eşiği, doğrudan Macro F1 Skorunu maksimize edecek ve Duyarlılığı (Recall) yüksek tutacak optimum noktalar hedeflenerek klinik risk minimize edilmiştir.

Panel Adı(Veri Seti)	Model Tipi	Macro F1 Skoru	MCC Skoru
PAH Paneli 269 Patojenik/ 7 Benign	LightGBM ve Ensemble	0.8972	0.7963
	CatBoost	0.8713	0.7489
	XGBoost	-	0.4882
	Ensemble Yaklaşım	0.8483	0.7087
CFTR Paneli 69 Patojenik/ 9 Benign	CatBoost	0.8523	0.7402
	Ağırlıklı Ensemble	0.7824	0.6364
	LightGBM	0.7524	0.5950
	XGBoost	-	0.0000
Hereditör Kanser Paneli 358 Patojenik/ 785 Benign	İleri Düzey Mimari(5 GBDT + ESM-2 + Stacking)	0.8932(F1)	-


Tablo2: Panel Bazlı Model Başa Metrikleri

4.3 Hata Analizi ve Model Davranışı (5 puan)

Performanslar incelendiğinde, CFTR panelindeki başarı oranının (MCC: 0.7402) PAH paneline (MCC: 0.7963) kıyasla daha düşük kaldığı görülmektedir. Bu durum veri setinin çok küçük olmasıyla doğrudan ilişkilidir. CFTR’de XGBoost’un MCC: 0.0000 ile tamamen başarısız olması, bu kadar kısıtlı örnekleme gradient boosting algoritmalarının aşırı öğrenme riski altında olduğunu gösterir.

Yanlış sınıflanan örneklerin özellik dağılımları incelendiğinde, Yanlış Pozitif (FP) örneklerin SIFT skorunun genel veri ortalamasının belirgin şekilde altında kaldığı görülmektedir; bu da modelin yüksek evrimsel baskıyı patojenik olarak algıladığını belirtmektedir. Yanlış Negatif (FN) örneklerde ise popülasyon frekansı (Allele Frequency) ve homozigot sayısı genel ortalamaya yakın değerler almakta olup, bu tablo modelin nadir ama zararlı varyantları popülasyon verisi içinde “yeterince nadir değil” olarak değerlendirip gözden kaçırdığını ortaya koymaktadır.

İn-silico skorların birlikte yüksek çıktığı benign varyantlar, çoklu skor kombinasyonunun modeli yanıltabileceğini açıkça ortaya koymaktadır. Biyokimyasal değerler açısından değerlendirildiğinde ise FP örneklerinin yüksek fizikokimyasal değişim gösteren ama işlevsel etkisi olmayan varyantlara karşılık geldiği anlaşılmaktadır. Buna ek olarak çoklu in-silico skorlarının (SIFT, CADD) birlikte yüksek çıktığı ancak klinik olarak benign olan varyantlar, model için en yanıltıcı örnek grubunu oluşturmaktadır. Özellikle CFTR panelinde yalnızca 9 benign örneğin bulunması, modelin negatif sınıf sınırını güvenilir biçimde öğrenmesinin önündeki temel engel olmaya devam etmektedir.



Tablo3: Genel Veri Setinin GBDT + Stacking Modeli SHAP Analizi

4.4 “Model Neden Böyle Karar Verdi?” – Açıklanabilirlik Yaklaşımı (5 puan)

Modelin karar mekanizması; SHAP, Ensemble Özellik Önemi ve Permütasyon Önemi analizleriyle açıklanabilir hale getirilmiştir. Döngüsellik yaratan REVEL ve PolyPhen gibi araçlar veri setinden silindiği için model, kararlarını kopya çekerek değil, tamamen biyolojik bağlamlardan almıştır. Genel kararlar incelendiğinde, iki panelde de Evrimsel Korunmuşluk ve In-Silico Skorlar en yüksek katkıyı sağlamış; Popülasyon Frekansları ikinci sırada yer alırken Biyokimyasal Etkiler bu kararları tamamlayıcı bir

rol üstlenmiştir. Sisteme gen bilgisi gizlenmiş olmasına rağmen modelin genin biyolojisini öğrendiği görülmüştür; PAH panelinde evrimsel baskı birinci sıradayken, CFTR panelinde protein katlanması önemli olduğundan Genomik Zararlılık ve Biyokimyasal Farklar öne çıkmıştır. Ayrıca permütasyon analizi, SIFT skorunun diğer in-silico skorlarla olan yüksek korelasyonu nedeniyle ayırt ediciliğinde keskin bir düşüş yaşadığını kanıtlamıştır. Eksik in-silico veriler için eklenen "Eksik Veri Bayrakları", model tarafından yalnız bir veri eksikliği olarak değil, başlı başına bir patojeniklik belirtisi olarak değerlendirilmiştir.

4.5 Öğrenme Süreci ve Teknik Evrim (5 puan)

Genel Veri Seti üzerindeki mimarimiz, yüksek skor hedefiyle tekil CatBoost modelinden, paneller arası varyansı düşüren "5 GBDT + Stacking" yapısına evrimleşmiştir. Amino asit dizilimlerini işlemek için önce Word2Vec gömmeleriyle "GBDT + Bagging + 1D CNN" test edilmiş, ancak yüksek karmaşıklık maliyeti nedeniyle daha gelişmiş bir Protein Dil Modeli olan ESM-2'ye geçilmiştir. Nihayetinde in-silico skorlar, biyokimyasal özellikler ve ESM-2'nin yapısal farkındalığı birleşerek en istikrarlı "5 GBDT + ESM-2 + Stacking" mimarisine ulaşmak amaçlanmıştır.

İlk modellerde F1 skoru 0.99'un üzerine çıkmış olsa da, değerlendirmeye MCC metriği eklendiğinde modelin aslında çoğunluk sınıfını ezberlediği fark edilmiştir. Bu yanlılığı kırmak için optimizasyon hedefi sadece doğruluktan çıkarılmış, azınlık sınıfı duyarlılığını ölçen Macro F1 ve MCC metriklerine geçilerek ezberleme şeffaflaştırılmıştır. Veri azlığı ve sınıf dengesizliğine karşı başlangıçta SMOTE ve Gaussian Noise gibi sentetik veri üretimi yöntemleri denenmiş; ancak bu işlemlerin evrimsel ve biyokimyasal nedensellik zincirini bozarak "imkansız varyantlar" ürettiği tespit edilmiştir. Bu nedenle sentetik veriden tamamen vazgeçilmiş, bunun yerine GBDT modellerinde ağaç derinliği kısıtlanarak (max_depth=2-4) L2 regularizasyonu artırılmış ve dengesizlik doğrudan sınıf ağırlıklandırmasıyla çözülmüştür. Son olarak, CFTR gibi küçük panellerde standart 5-Fold CV'nin rastlantısal olarak yanıltıcı iyi sonuçlar ürettiği görülmüş ve bunu önlemek için Repeated Stratified 5-Fold CV benimsenmiştir. Tekil modellerin zaafılarını kapatmak amacıyla da "Ağırlıklı Soft Voting" ve "Stacking" ensemble mimarileri kurularak sistem her iki gen panelinde de genellenebilir hale getirilmiştir.

5. YAKLAŞIMIN GEREKÇESİ, KAYNAK KULLANIMI VE ÖZGÜNLÜK (25 PUAN)

5.1 Neden Bu Algoritma / Mimari? (5 puan)

Tek bir algoritmaya bağlı kalmak yerine farklı matematiksel temellere dayanan yöntemler bir arada kullanılarak çok katmanlı bir ensemble model tasarlanmıştır. Ortalama 4-5 algoritma (XGBoost, LightGBM, CatBoost, Random Forest, Extra Trees, SVM, Logistic Regression, CNN , ESM-2) birlikte çalıştırılmış, her biri farklı örüntüleri

yakalama ve hata profillerini tamamlama amacıyla seçilmiştir. Gradyan artırmalı ağaçlar karmaşık doğrusal olmayan ilişkileri öğrenip NaN değerleri tolere ederken, bagging yöntemleri bootstrap örnekleme ile overfitting'i azaltmıştır. SVM küçük veri setlerinde genelleme yaparken lojistik regresyon hem baseline hem de meta learner olarak denge sağlamıştır. Bu mimari, klinik riskleri en aza indirmek için ağırlıklı soft voting ve stacking stratejileriyle kurulmuş, MCC ve F1 değerleri arasındaki denge algoritmik çeşitlilikten beslenen gürültüye dayanıklı ve genellenebilir bir model ortaya koymuştur.

5.2 Alternatifler Neden Elendi? (5 puan)

Süreç boyunca birçok alternatif yaklaşım denenmiş ve elenmiştir

Elenen başlıca yaklaşımlar ve gerekçeler şunlardır :

1. CTGAN ile sentetik veri üretimi : CFTR ve PAH gibi az sayıda benign örneği içeren veri setlerini büyütmek ve dengeli hale getirmeye çalışmak için sentetik veri üretimi değerlendirilmiş ancak frekanslar, cadd skorları ve phyloP arasındaki ilişkilerin sentetik veri üretim sırasında bozulduğu gerçek hayatta mümkün olmayan değerlerin üretildiği ve azınlık sınıfı verilerinin kendisinden orantısız miktarda veri üretmek zorunda kalarak gerçeklikten uzaklaştığı yapılan deneyler sonucunda ortaya konmuştur bu sebepten ötürü veri üretmek yerine Ensemble modeller Regularizasyon teknikleri ve algoritmaların sınıf ağırlıklandırılmaları kullanılarak aşırı öğrenmenin (overfitting) önüne geçilmesi hedeflenmiştir.
2. Hibrit Derin Öğrenme Mimarileri : Sekans analizi için tasarlanan Hibrit derin öğrenme (CNN + Dense v1) modeli AUC = 0.5000 ve F1= 0.6750 gibi bir sonuçla performans yetersizliğinden ve derin sinir ağlarının GPU ihtiyacının yüksek olması ve eğitim maliyetinin pratik kullanımı zorlaştırması nedeni ile ana karar mekanizmasından çıkarılmış . Literatürde genetik varyant patojenitesi tahmini üzerine makine öğrenmesi ile derin öğrenmeyi kıyaslayan çalışmalarla uyum göstermiştir.

5.3 Parametre Seçimi ve Model Ayarları (5 puan)

Hiperparametre optimizasyonu tek tip yapılmamış her panel için OPTUNA kütüphanesi ile ayrı ayrı gerçekleştirilerek en uygun parametreler seçilmiştir Modelin aşırı öğrenmesini engellemek için 50 iterasyonluk early stopping ve L1/L2 düzenlenileştirilmesi uygulanmıştır. Threshold varsayılan 0.5 te bırakılmamış Precision-Recall eğrisi üzerinden F1 skorunu maksimize eden optimal karar eşikleri panel ve algoritma bazında ayrı ayrı hesaplanarak FN ve FP takasları klinik risklere göre uyarlanmıştır.

5.4 Hesaplama Kaynakları ve Çalıştırılabilirlik (5 puan)

Modellerin eğitim süreçleri Google Colab ortamında, Linux tabanlı ve 13.6 GB RAM'li GPU'suz standart ortamda yürütülmüş, yalnızca ESM-2 gibi ağır tensör işlemleri için GPU kullanılmıştır. Python 3.12.13 üzerinde scikit-learn 1.6.1, xgboost 3.2.0, lightgbm 4.6.0,

catboost 1.2.10, optuna==4.8.0, shap 0.51.0 , pandas ve numpy; doğal dil işleme ve özellik çıkarımı için tensorflow gensim faiss kullanılmıştır. Tabular modeller CPU çoklu çekirdek ve histogram tabanlı algoritmalarla paralel çalıştırılarak RAM sınırının altında kalmış, Optuna ile 5-Fold CV optimizasyonu dahil eğitim panel başına 10-15 dakikada tamamlanmıştır. ESM-2 modeli 7360 protein dizisini(batch_size=128) GPU ile 20 dakikada işlerken, Optuna araması 30-35 dakika, optimize edilmiş parametrelerle standart eğitim 20-30 dakika, Nested CV ise CPU ortamında 45-60 dakikada bitirilmiştir. Tüm süreçlerde deterministik seed (42) sabitlenerek tekrarlanabilirlik sağlanmıştır. Tek bir varyantın analiz edilmesi CPU üzerinde iterasyon başına eğitim süresi 10-20 milisaniyedir. Binlerce varyanttan oluşan VCF tablosunun toplu değerlendirilmesi 1-2 saniye sürmektedir.

5.5 Özgünlük (5 puan)

Amino Asit Sözlüğü : Biyokimyasal fark skorlarına (Delta_MW, Delta_Hydro vb.) Python da amino asit sözlüğü oluşturularak ulaşılmıştır. Bu skorlar literatürde yer alan Alfa Chemistry'nin pH 7.0 bazlı normalize edilmiş hidrofobiklik indeksi başta olmak üzere halka açık amino asit özellik tablolarından türetilmiştir.

Öznitelik Oluşturma : Sadece alel frekanslarını kullanmak yerine “benign varyantların %47.75’inde en az bir homozigot birey gözlemlenirken, patojenik varyantlarda bu oranın yalnızca %1.51 olması ” biyolojik gerçeğinden yola çıkarak Total_Homozygotes ve Is_Homozygote_Present gibi tamamen bize özgü değişkenler türettik .

VARITY Standardına Dayalı İki Katmanlı De- duplikasyon Stratejisi : Veri setinde farklı transkriptlerden kaynaklanan tekrar edilen kayıtların tekilleştirilmesinde rastgele bir seçim yapılmamış AA_Context_11 (11 li komşuluk amino asit dizisi) değişkeni birleştirme anahtarına dahil edilmiştir. Bu stratejik hamle sayesinde veri setinde “çelişkili etiket ” gibi görünen 555 varyantın aslında farklı protein pozisyonlarından ve bağlamlarından kaynaklandığı kanıtlanmış ve gereksiz veri kaybının önüne geçilmiştir.

Doğal Dil İşleme ile Sekans Analizi : genomik ve proteomik komşuluk dizilerinin basit bir metin olarak bırakmayıp Word2Vec ve 1D CNN mimarileri işe 32 boyutlu yapısal vektörlere dönüştürdük.

6. REFERANSLAR

- [1] J. Lai, J. Yang, E. D. Gamsiz Uzun, B. M. Rubenstein, ve I. N. Sarkar, "LYRUS: a machine learning model for predicting the pathogenicity of missense variants," *Bioinformatics Advances*, vol. 1, no. 1, vbab045, 2021
- [2] D. Mahecha, H. Nuñez, M. C. Lattig, ve J. Duitama, "Machine learning models for accurate prioritization of variants of uncertain significance," *Human Mutation*, vol. 43, no. 4, pp. 449-460, 2022
- [3] Y. Wu, H. Liu, R. Li, S. Sun, J. Weile, ve F. P. Roth, "Improved pathogenicity prediction for rare human missense variants," *The American Journal of Human Genetics*, vol. 108, no. 10, pp. 1891-1906, 2021
- [4] J. Liu, Y. Chen, K. Huang, ve X. Guan, "Enhancing Missense Variant Pathogenicity Prediction with MissenseNet: Integrating Structural Insights and ShuffleNet-Based Deep Learning Techniques," *Biomolecules*, vol. 14, no. 9, p. 1105, 2024
- [5] A. Schmidt, S. Röner, K. Mai, H. Klinkhammer, M. Kircher, ve K. U. Ludwig, "Predicting the pathogenicity of missense variants using features derived from AlphaFold2," *Bioinformatics*, vol. 39, no. 5, btad280, 2023